



Présentation du projet DATA

ZAMOUN
GRETA -DATA ANALYST
20/02/2026

La mission :

📌 Rapprochement et analyse de nos bouteilles de vin




- Identifier les produits qui tirent le chiffre d'affaires.
- Détecter les ruptures, les surstocks et les marges faibles.
- Donner une vision exploitable pour le CODIR afin de challenger les équipes commerciales et logistiques.

Optimiser la gestion des données d'une Boutique de vins - Bottleneck

📌 Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données

☑ Méthodologie de Rapprochement de l'extraction de la BDD Web avec la base de données ERP via la table de liaison



☑ Contraintes :

- Centraliser et fiabiliser les données issues de plusieurs systèmes
- Réaliser une analyse exploratoire complète
- Détecter les anomalies (prix, stocks, doublons, valeurs manquantes)
- Préparer les données pour des analyses avancées (corrélations, Pareto, marges...)
- Construire un pipeline d'analyse reproductible
- Générer un fichier final consolidé pour exploitation métier

Livable : Notebook Jupyter Python incluant la DataViz

Analyses exploratoires des données



Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données



Identification des erreurs dans les données **ERP**

Df_ERP : 4 INCOHERENCES

4 Lignes en écarts In/OutStock : A
corriger (4039,4885,4973,5700)

Df_ERP : 2 ERREURS DE SAISIE

2 Lignes quantités négatives : A
corriger 4973: -10 → 0 , 5700: -1 →
0

Df_ERP : 3 ERREURS PRIX
NEGATIFS

A Analyser (4233:-20), (5017: -8.0),
(6594: -9.1)

Préparation de la colonne « web_disponible » pour le calcul du CA, 92 produits en rupture de stock à analyser

Analyses exploratoires des données



Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données



Identification des erreurs dans les données **Web**

Df_web : 4 INCOHERENCES

4 Lignes sans Format Ligne 272 (13127-1), Ligne 842 (bon-cadeau-25-euros), **ligne 1117 (13127-1) et ligne 1387 (bon-cadeau-25-euros)**

Df_web: 1428 Doublons : utilisation de la méthode
drop_duplicates(subset=[sku_col],
keep='first')

Df_web: 85 suppressions de Lignes sans CODE ARTICLE après complétion des données à étape de Nettoyage

Préparation de la colonne « Web disponible » et « Total_Sales » pour le calcul du CA

Analyses exploratoires des données



Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données



Identification des erreurs dans les données **Liaison**

Df_liaison : 4 ANOMALIES de
FORMAT
2: 1317- et Bon pour cadeau 25
euros + 2 doublons supprimés

Df_liaison : 91 doublons id_web
sans correspondance
supprimés

Df_liaison : **20 Valeurs
manquantes**

Création automatique de Reporting et Workflow de vérification des Id_web manquants : 89% Matching ERP/WEB

Fusion ou consolidations des données



Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données

✓ Fusion des dataframes + préparation et nettoyage des données pour faire des analyses avancées

Articles ERP initiaux: 825

Dataset final: 713 lignes

Articles web nettoyés: 712

Liaisons valides : 805

Phase	dataset	chargement	Doublons	onsale=1	manquants	sans id_web	tax_status (taxables not NAN)	anomalies SKU	post_type[product]=NAN	web_dispo
Phase I : agréger les données : Analyse exploratoire	erp	(825,6)	0	716						716
	web	(1513,29)	1428				714	2		712
	liaison	(825,2)	91	734	20					714
Phase I : agréger les données : Fusion ou Consolidation	df_merge (erp+liaison) avant fusion	(825,9)	0			111				714
	web (renommage sku en id_web)	(714,6)	0						1	713
	final (merge+web) inner id_web = df_test_merge	(713,14)	0							713
	Marge négative =1									712
Phase II : Analyses univariées et avancées	final colonnes : product_id', 'onsale_web', 'price', 'stock_quantity', 'stock_status', 'purchase_price', 'marge_brute', 'taux_marge_pct', 'id_web', 'total_sales', 'tax_status', 'product_type', 'post_type', 'post_name'									

Bonne cohérence ERP → Conserver df_final comme base unique pour les analyses suivantes, Utiliser df_final pour les visualisations et KPIs

Analyses exploratoires des données



Phase I : Agréger les différents fichiers sourcés afin de pouvoir exploiter les données



- ☑ propositions des solutions pour améliorer les données dans nos systèmes

Améliorer la base de données ERP et WEB par un processus d'amélioration continue en consolidant l'intégrité référentielle en base (clé primaire , gestion des erreurs, anomalies et alertes) par un travail collaboratif

Création automatique de Reporting et Workflow de vérification de prix négatifs

Création automatique de Reporting et Workflow de vérification des SKU anomalies


Création automatique de Reporting et Workflow de vérification des Id_web manquants

Recommandation : Marquer les 113 articles = 111 non disponibles web + 2 erreurs de saisies comme non disponibles web avant analyses CA

Optimiser la gestion des données d'une — Boutique de vins - Bottleneck

Phase II : Analyses des données

- ☒ Analyses univariées, analyses avancées et sauvegarde avec Notebook Jupyter



-  86.8% du catalogue est disponible en ligne
-  Stock moyen 2.28x plus élevé pour articles en ligne (23.3 vs 10.2)
-  4 anomalies stock/status corrigées en phase 1
-  1 colonne redondante supprimée
-  100% cohérence données après correction

- ☐ Calcul du CA Global , par produit
- ☐ Top références , Pareto (le 20/80)
- ☐ Vérification de potentielles valeurs aberrantes, erreurs de saisie ? (Calculs Z-Score, IQR)
- ☐ Extraction des valeurs aberrantes dans les prix (boxplot), erreurs de prix ?
- ☐ Analyses sur l'état, les taux de marge, la rotation des stocks ou le nombre de mois de stock
- ☐ Corrélation entre certaines données quantitatives (prix, prix d'achat, stock, ventes, prix HT et taux de marge etc ...) ?

Analyses des données

Phase II : Analyses des données

- ☒ Analyse univariée Calcul du CA Global web_disponibles, par article (**Palmares Plotlib**)

CA total estimé : 143,505.10€
pour 713 articles

Différence avec octobre réel (143 680, 10€):
175.00€

Différence avec valorisation du stock
(494,062.90€ - 143 680, 10€) : 350 557,8 €
au mois d'octobre (peut-être en prévision
des fêtes ?)

Limite : CA = Prix x Total_ventes (calculé , non
réel)

Analyses des données


Phase II : Analyses des données

- ☒ Analyse Palmarès TOP Références


Sur les 20 articles ,le Champagne a le plus fort CA en Valeur

Mais c'est la catégorie Vins qui se distingue en Volume

TOP 20 Articles par Chiffre d'Affaires (ordre décroissant)



Histogramme du CA estimé par product_type



Analyses des données


Phase II : Analyses des données

- ☒ Analyse avancée PARETO (LOI 20/80 en CA)


433 articles (60,73%) font 80% CA

280 articles (54,5%) font 20% CA

Courbe de Pareto - CA Cumulé (%)



Courbe de Pareto - CA Cumulé (%) par Type de Produit



Pourcentage du catalogue: 60.73% font 80% du CA

Analyses des données

Phase II : Analyses des données

13 Valeurs Aberrantes

31 Outliers

Dont le Champagne **4352** :
225 €

Analyses univariées de la Variable **PRIX**

•Détection des valeurs aberrantes

****Méthodes**

statistiques : Z-Score**

- 1. Moyenne : 32,34 EUR**
- 2. Écart-type : 27,61 EUR**
- 3. Prix avec $|z| > 3$: 13**

****Méthodes**

statistiques : IQR**

- Q1 = 25% : 14,05
- Q2 = 50% : 23,40
- Q3 = 75% : 42,10
- Seuils IQR:
- Bas : -28,03 EUR
- Haut : 84,18 EUR
- Nb Outliers : 31
- Proportion (IQR) : 4,35%

La dispersion des valeurs centrales (entre le 1er et le 3e quartile) est faible. Les produits ont des valeurs assez proches les uns des autres sur la variable price

Analyses des données

Phase II : Analyses des données

Q1 : 14.05€

Q2 (Médian) : 23,4 €

Q3 : 42€


Min : -28,03€

Max : 225€

☑ **DataViz** : Extraction des valeurs aberrantes dans les prix (boxplot)

****DataViz :BoxPlot Plotly****

- Max : 225€ parmi les 36 Outliers
- Moustache haute : 84,18€
- Q3:42€
- Q2 (Médian) : 23,4€
- Q1:14.05€
- Min : -28,03€



Limite : Max = 225 € (parmi les Outliers) + **Min = -28,03 €** (signe négatif) erreurs de prix seulement ?

Analyses complémentaires CA, quantités, stocks, taux de marge et corrélations



Phase II : Analyses des données

- ☒ **DataViz** : Histogramme sur le taux de marge de 712 articles web avec marge positive

Taux médian :
61.27%


Taux Moyen :
61.23%

Taux Min : -
29.50%

Taux max:
Max: 91.41%

Max: 100,63€

Moyenne :
15,25€
(positive)



```
=====
⚠ DÉCOUVERTE CRITIQUE: 7 ARTICLES EN PERTE
=====

📊 Nombre d'articles en perte (marge ≤ 0): 1

🔴 LISTE DES ARTICLES EN PERTE:
  product_id price purchase_price marge_brute taux_marge
201         4355      12.65          77.48    -66.938333   -86.394338

📄 FORMAT TABLEAU:
| product_id | Prix vente | Prix achat | Marge | Taux marge |
|-----|-----|-----|-----|-----|
| 4355 | 12.65€ | 77.48€ | -66.94€ | -86.39% |

💡 RECOMMANDATIONS:
🔴 Product 4355: CRITIQUE (perte -66.94€) → SUPPRIMER ou Corriger immédiatement
```

Limite : Product 4355 perte – 66,94 € : à retirer.

Analyses complémentaires


CA, quantités, stocks, taux de marge et corrélations



Phase II : Analyses complémentaires des données

- ☑ **DataViz** : Analyse sur la Corrélation entre certaines données quantitatives (prix, prix d'achat, stock, ventes, prix HT et taux de marge etc ...) ?

Matrice de corrélation - Tous produits



Corrélations positives en Bleu: 0.97 :
Price → price_ht, price → purchase_price

Corrélations positives en Bleu: 0.71 :
Ca_par_article → stock_quantity mais
taux de marge → -0,42

Corrélations négatives en rouge
Price ← Rotation du Stock = - 0.70 (corrélation négative forte)

Analyses complémentaires CA, quantités, stocks, taux de marge et corrélations



Phase II : Analyses des données

☑ **DataViz** : Visualisation de la rotation des stocks

Stock Tous
produits :
298,627.66 €

stock web:
276,859.09 EUR
(92.7%)


Stock non web:
21,768.57 EUR
(7.3%)

TOTAL Stock
unités: 17,822


stock web:
16,711 unités
(93,8%)

Stock non web: 1,111
unités (6,2%)

IDP - Indice de Disponibilité des Produits (%)




Distribution des Produits par Performance IPR



Actions pour la suite

- Corriger prix/stock négatifs
- Traiter surstocks et ruptures
- Optimiser pricing sur top CA
- Mettre a jour donnees web/liaison
- Suivi via dashboard



Point sur les compétences apprises

- Préparation et fusion multi-sources
- Analyses statistiques + visualisations
- Automatisation reporting
- Dashboard Streamlit + deploy
- Communication des résultats

"Défi rencontré : Problème de correspondance entre les tables "

Les clés de liaison entre df_web et df_liaison ne correspondaient pas parfaitement
Seulement 3 correspondances sur 825 produits;
Correction de la Fusion df_merge + df_web

"Défi rencontré : Problème de doublons « et calcul du CA sur le Total_sales, non pas sur le stock grâce à mon mentor.

"Défi rencontré : Switcher entre datasets dans la gestion des doublons et analyser 2 a 2 voire 3 par 3